

Predicción de resultados del fútbol uruguayo mediante métodos de aprendizaje supervisado

Thiago Rivas
C.I. 5.475.680-3
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
thiago.rivas0021@gmail.com

Juan Duarte
C.I. 5.201.302-9
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
juan.duarte@fing.edu.uy

Agustin Occhiuzzi
C.I. 5.480.562-4
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
agustin.occhiuzzi@fing.edu.uy

Resumen—Se estudia la predicción de victoria local, visitante o empate mediante atributos históricos causales y validación temporal. Se usan 14.705 partidos hasta 2023 para entrenamiento y 472 de 2024–2025 para evaluación. La validación anual 2021–2023 selecciona diez entradas para ID3 y ambos Naive Bayes, y seis para Random Forest. En la evaluación final, Naive Bayes obtiene accuracy 0,4788 y macro-F1 0,4454; ID3, 0,4492 y 0,4238; Random Forest, 0,4258 y 0,4219; y el baseline de diez años, 0,4619 y 0,3564. Los dos NB producen las mismas 472 clases predichas. La principal dificultad compartida es reconocer empates; se analizan los errores y las limitaciones del diseño experimental.

Index Terms—aprendizaje supervisado, árboles de decisión, Naive Bayes, predicción deportiva, fútbol uruguayo

I. INTRODUCCIÓN

La predicción de resultados del fútbol uruguayo se plantea como un problema de clasificación supervisada con tres clases, los cuales son victoria local (L), victoria visitante (V) y empate (E). A partir de registros históricos de partidos, se busca construir atributos disponibles antes del encuentro y estimar su resultado. El desafío no es únicamente ajustar un clasificador, también requiere respetar el orden temporal y evitar que el resultado que se intenta predecir intervenga en sus entradas.

Este trabajo aborda la aplicación de herramientas metodológicas a datos reales, la implementación de métodos supervisados y el análisis de sus predicciones. Se implementaron un árbol ID3 con umbral mínimo de ganancia de información, un Naive Bayes categórico con suavizado mediante tamaño equivalente de muestra y el clasificador base de proporción de victorias en los diez años anteriores. La comparación incluye CategoricalNB y Random Forest de scikit-learn.

El procesamiento parte de seis tasas históricas de victoria y separa 2024–2025 para evaluación. Para ID3 y ambos NB, la validación seleccionó diez atributos: esas tasas más puntos y diferencia de gol por partido de cada equipo en hasta cinco antecedentes previos. El bosque conserva las seis tasas. Se examinan métricas por clase además de la proporción global de aciertos.

La configuración se elige mediante validación y luego se ajusta una vez con todo el entrenamiento. La evaluación final verificada usa esa configuración congelada; las curvas de validación no son resultados de test.

II. CONJUNTO DE DATOS Y PREPROCESAMIENTO

II-A. Descripción del dataset

Se utiliza el subconjunto de fútbol uruguayo de la colección de David Schoch [1], suministrado en un ZIP con un único CSV. El archivo contiene 15.207 filas y 17 columnas, tras el procesamiento quedan 15.177 partidos, desde el 5 de marzo de 1932 hasta el 30 de junio de 2025. Por tanto, 2025 no representa un año completo. Los campos centrales son fecha, equipos local y visitante, y goles registrados (gh, ga).

II-B. Limpieza de datos

La carga normaliza espacios y tipos además de exigir goles enteros no negativos. Elimina una repetición exacta. Se identifican siete grupos ambiguos de fecha y par de equipos, incluyendo localías invertidas, por lo que se excluyen sus 16 registros completos, sin elegir un marcador. Además, se descartan cinco filas de prórroga y ocho de penales. Todas estas exclusiones se aplican antes de construir historiales. Se conserva un registro de motivos y líneas del CSV. Las 175 filas admitidas con advertencias de múltiples encuentros de un equipo en una fecha mantienen sus fechas originales, no se dispone de evidencia para corregirlas. La causalidad se entiende respecto de las fechas registradas.

II-C. Construcción de la variable objetivo

Se adopta el resultado reglamentario sobre los registros con `full_time` igual a F. La etiqueta `winner` se define como

$$\text{winner} = \begin{cases} \text{L} & \text{si } gh > ga, \\ \text{V} & \text{si } gh < ga, \\ \text{E} & \text{si } gh = ga. \end{cases}$$

El diccionario de la fuente incluye prórroga y penales en los goles [1], pero no separa marcadores reglamentarios: las ocho filas P del archivo presentan goles iguales. Se excluyen E/P por incertidumbre, sin reconstruir goles ni imponer empates, lo que limita la cobertura del estudio. Los goles actuales y `full_time` no son entradas de los clasificadores.

II-D. Atributos derivados

Se construyen seis tasas: proporción de victorias en los últimos cinco partidos de cada equipo, proporción de victorias de ambos dentro del año calendario, proporción histórica de victorias del local jugando como local y proporción de victorias de ese local frente al visitante con la misma localía. Si hay menos de cinco antecedentes se usan los disponibles, la referencia anual no corresponde necesariamente a una temporada deportiva.

El cálculo recorre fechas y obtiene los atributos de todos los encuentros de un día antes de actualizar cualquier historial de ese día. Así excluye resultados simultáneos y futuros. Cuando no hay antecedentes se asigna 0,5: esto evita equiparar ausencia de historial con cero victorias, pero puede coincidir con una tasa observada y no constituye una categoría independiente. Nombres de equipos y mes no integran las seis entradas; los nombres sirven para enlazar historiales. Para la variante de diez atributos de ID3 y NB se agregan cuatro entradas: puntos por partido y diferencia de gol por partido en hasta cinco antecedentes, para local y visitante. Los puntos son 3/1/0 y la diferencia es goles a favor menos goles en contra; sin antecedentes se asignan 4/3 y 0. Estas diez entradas, seleccionadas por validación, no incluyen goles del partido a predecir.

II-E. Discretización

El discretizador común produce códigos enteros para ID3 y ambos NB. Para las tasas de los últimos cinco partidos se fijan cortes en 0,3 y 0,6, es decir, baja si $x < 0,3$, media si $0,3 \leq x < 0,6$ y alta en otro caso. Las otras ocho entradas usan terciles aprendidos solo con entrenamiento y reutilizados en validación o evaluación. Los cortes repetidos se eliminan, por lo que pueden resultar menos de tres intervalos; los empates entre valores tampoco garantizan grupos de igual tamaño. No existe un intervalo exclusivo para “sin historial”. Los valores numéricos no finitos se imputan con la mediana aprendida en entrenamiento.

II-F. División temporal de datos

Se separan temporalmente 14.705 partidos hasta 2023 como set de entrenamiento y 472 de 2024–2025 para evaluación. Los atributos de evaluación incorporan resultados de fechas anteriores del propio período, simulando predicciones sucesivas, sin reajustar el modelo. La misma política rige para el clasificador base: todos disponen de resultados de fechas anteriores, incluidos los del bloque de evaluación.

III. MODELOS

III-A. Clasificador base

TenYearWinRateClassifier compara las tasas causales de victoria de los diez años anteriores, producidas por el mismo constructor de atributos. Incluye resultados de fechas anteriores del bloque evaluado y excluye el día actual. Sin antecedentes asigna 0,5, ante igualdad elige al local. Nunca predice empate y no aprende parámetros ni modifica historiales al predecir.

III-B. Árbol de decisión propio

La implementación utilizada es ID3. En cada nodo selecciona el atributo de mayor ganancia de información y crea una rama por categoría observada. Para un conjunto S , con proporción p_c de ejemplos de clase c , utiliza:

$$H(S) = - \sum_{c \in \{L,V,E\}} p_c \log_2 p_c \quad (1)$$

$$IG(S, A) = H(S) - \sum_{v \in \text{valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad (2)$$

Los términos con $p_c = 0$ se omiten. Cada atributo se usa como máximo una vez por rama. La recursión termina si el nodo es puro, no quedan atributos, se alcanza `max_depth` (8 como default) o ninguna ganancia supera estrictamente `min_info_gain`. Este último criterio realiza preprda. Cada nodo guarda su clase mayoritaria, que sirve de respaldo ante una categoría no observada, los empates se resuelven por orden de clase. El código contempla ramas vacías, aunque la construcción recorre únicamente categorías presentes.

III-C. Naive Bayes propio

MEstimateCategoricalNB estima las probabilidades de clase mediante frecuencias y supone independencia condicional entre atributos. Para el código v del atributo j y la clase c aplica:

$$P(X_j = v | c) = \frac{n_{jvc} + m/K_j}{n_c + m} \quad (3)$$

Aquí n_{jvc} cuenta coincidencias de código y clase, n_c cuenta ejemplos de la clase y K_j es el máximo código de entrenamiento más uno, o el mínimo declarado mediante `min_categories` si es mayor. La grilla declara cuatro códigos en ambos NB, incluso con bins ausentes, en general K_j puede variar entre atributos y un único $\alpha = m/K$ solo es equivalente con un dominio común de tamaño K . El cero queda reservado para desconocidos. El parámetro $m > 0$ es el tamaño equivalente de muestra: reparte un peso total m uniformemente entre las K_j categorías, agregando m/K_j a cada conteo. Se decide por $\arg \max_c [\log P(c) + \sum_j \log P(X_j = x_j | c)]$, con desempate E/L/V. Los códigos fuera del dominio se remiten al cero; el prior de clase $P(c) = n_c/N$ no se suaviza.

III-D. Modelos de referencia

El Random Forest combina 300 árboles entrenados sobre las seis tasas continuas, con semilla 42 y ponderación de clases en cada muestra bootstrap (`balanced_subsample`). El baseline compara las tasas causales de diez años ya descritas.

Para comparar con el Naive Bayes propio se utiliza CategoricalNB, aplicado sobre la misma discretización y con cuatro códigos por atributo (incluyendo el código reservado para valores desconocidos). Este estimador calcula las probabilidades condicionales como $(n_{jvc} + \alpha)/(n_c + K_j \alpha)$. Cuando $K_j = 4$ y $\alpha = m/4$, y ambos modelos comparten el mismo prior de clase empírico y las mismas entradas, esta fórmula coincide exactamente con la del NB propio

(Ecuación 3). El suavizado indicado se respeta sin truncar, y el prior de clase se aprende a partir de train. El ajuste final de ID3 y ambos NB utiliza las diez entradas elegidas por validación. El bosque conserva seis tasas y usa la profundidad y hoja mínima seleccionadas en su grilla.

IV. EXPERIMENTACIÓN

IV-A. Selección temporal de hiperparámetros

Se validó en los años completos 2021, 2022 y 2023, con entrenamiento expansivo anterior a cada año. Las fechas no se dividen entre conjuntos y cada combinación ajusta un pipeline nuevo por fold. La selección utiliza macro-F1 medio con igual peso por año. El error graficado es $1 - \text{accuracy}$; el error de entrenamiento es de resustitución y no interviene en la elección.

Se exploraron seis umbrales ID3 entre 0 y 0,05, cinco valores de m entre 0,1 y 1000, cinco de $\alpha = m/4$ y doce combinaciones de profundidad (4, 8, sin límite) y hoja mínima (1, 5, 20, 50) del bosque. Este mantiene 300 árboles y semilla 42. Ante empate exacto se favorece menor umbral o suavizado; para el bosque, menor profundidad y mayor hoja.

ID3 seleccionó 0,005 (macro-F1 0,3818 sobre seis tasas), ambos NB seleccionaron el menor suavizado ($m = 0,1$, $\alpha = 0,025$), con macro-F1 0,3635. Sus métricas coinciden bajo el dominio común de cuatro códigos. Random Forest seleccionó profundidad sin límite y hoja mínima 20: macro-F1 0,4228 y error 0,5653. Esta configuración controla su ajuste final; se mantienen 300 árboles, semilla 42 y ponderación `balanced_subsample`. El notebook presenta error de entrenamiento y validación para ID3, ambos NB identificados explícitamente (curvas superpuestas) y las doce configuraciones del bosque.

IV-B. Comparación acotada de atributos

Con hiperparámetros fijos se compararon únicamente las seis tasas y esas tasas más puntos y diferencia de gol recientes de ambos equipos, diez entradas. La misma función de validación ajusta cortes fijos [0,3,0,6] solo para las dos tasas de los últimos cinco partidos; el resto usa terciles aprendidos en cada train. Los mismos folds seleccionaron diez entradas para ID3 y ambos NB: macro-F1 0,4002 y 0,3858, con errores 0,5846 y 0,5723, respectivamente. En empate exacto se prefieren seis entradas. Estas selecciones determinan las columnas del ajuste final; el bosque mantiene las seis tasas. No se reoptimizan hiperparámetros y el cálculo de selección no usa las filas de test. Reutilizar folds para decisiones sucesivas puede introducir optimismo.

V. RESULTADOS

Cada modelo se reajustó con los 14.705 partidos hasta 2023 usando la configuración elegida por validación y se evaluó sobre los mismos 472 encuentros. Discretizadores y clasificadores permanecen fijos. Los atributos de cada partido sí incorporan resultados de fechas anteriores de 2024–2025, como en una secuencia de predicciones; nunca incorporan partidos de la misma fecha. El bloque contiene 131 empates,




Figura 1. Error de entrenamiento/validación y macro-F1 de validación para ID3; medias de los tres años.




Figura 2. Error y macro-F1 para NB propio y sklearn CategoricalNB ($\alpha = m/4$); curvas equivalentes superpuestas sobre las seis tasas iniciales.




Figura 3. Error de entrenamiento/validación y macro-F1 de validación del bosque según profundidad y hoja mínima. Se selecciona profundidad sin límite y hoja mínima 20.

190 victorias locales y 151 visitantes. Como referencia adicional, predecir siempre L obtiene accuracy 0,4025 y macro-F1 0,1913.

Tabla I
EVALUACIÓN COMÚN SOBRE LOS 472 PARTIDOS DE 2024–2025

Modelo	Accuracy	Macro-F1
ID3 propio	0,4492	0,4238
Naive Bayes propio	0,4788	0,4454
CategoricalNB (sklearn)	0,4788	0,4454
Baseline (diez años)	0,4619	0,3564
Random Forest	0,4258	0,4219

Los dos NB aciertan 226 encuentros y generan las mismas 472 etiquetas. La diferencia absoluta máxima entre sus probabilidades es $2,0 \cdot 10^{-15}$, dentro de la precisión numérica y sin alterar el *argmax*. Frente al baseline, NB obtiene ocho aciertos adicionales: mejora accuracy en 1,69 puntos porcentuales y macro-F1 en 0,0889. ID3 y Random Forest tienen menor accuracy que el baseline, aunque mayor macro-F1. Esta distinción importa porque el criterio elegido para seleccionar modelos asigna el mismo peso a las tres clases, mientras que accuracy pondera cada clase según su cantidad de partidos.

Tabla II
MÉTRICAS POR CLASE. AMBOS NB TIENEN IDÉNTICOS VALORES

Modelo	Clase	Precision	Recall	F1	n
NB (ambos)	E	0,3537	0,2214	0,2723	131
	L	0,5475	0,6368	0,5888	190
	V	0,4497	0,5033	0,4750	151
Baseline	E	0,0000	0,0000	0,0000	131
	L	0,5021	0,6368	0,5615	190
	V	0,4199	0,6424	0,5079	151
ID3	E	0,3036	0,2595	0,2798	131
	L	0,4917	0,6211	0,5488	190
	V	0,5000	0,3974	0,4428	151
Random Forest	E	0,2975	0,3588	0,3253	131
	L	0,5725	0,4158	0,4817	190
	V	0,4261	0,4967	0,4587	151

V-A. Matrices de confusión

Con filas reales y columnas predichas en orden E/L/V, las matrices verificadas son:

$$C_{ID3} = \begin{pmatrix} 34 & 64 & 33 \\ 45 & 118 & 27 \\ 33 & 58 & 60 \end{pmatrix}, \quad C_{NB} = \begin{pmatrix} 29 & 54 & 48 \\ 24 & 121 & 45 \\ 29 & 46 & 76 \end{pmatrix},$$

$$C_{RF} = \begin{pmatrix} 47 & 34 & 50 \\ 60 & 79 & 51 \\ 51 & 25 & 75 \end{pmatrix}, \quad C_{base} = \begin{pmatrix} 0 & 66 & 65 \\ 0 & 121 & 69 \\ 0 & 54 & 97 \end{pmatrix}.$$

CategoricalNB comparte la matriz de NB propio. En todos los modelos, E tiene el menor F1. De los 246 errores del NB, 102 son empates clasificados como victorias: 54 como L y 48 como V. Además, confunde 91 victorias locales con visitantes o viceversa, y produce 53 falsos empates. Reconoce solo 29 de los 131 empates reales (recall 22,1%), aunque sus 121 aciertos en L y 76 en V sostienen el mejor resultado global de la comparación.

Frente al baseline, NB mantiene la cantidad de victorias locales acertadas (121), reconoce 29 empates y pierde 21 aciertos en V (76 frente a 97). El saldo son ocho aciertos adicionales; el F1 mejora en E y L, pero baja en V (0,4750 frente a 0,5079). Por tanto, su ventaja no es uniforme entre clases.

ID3 predice L en 240 partidos, frente a 190 victorias locales reales, y reconoce 34 empates (26,0%). El bosque reconoce 47 empates (35,9%), pero predice E en 158 encuentros y 111 de ellos no son empates. Capturar más E tiene un costo en falsos positivos y en aciertos de las otras clases: por eso Random Forest alcanza el mayor F1 de E (0,3253), sin obtener la mayor accuracy ni macro-F1 global.

V-B. Análisis cualitativo

Se ordenaron las predicciones finales por fecha, local y visitante y se tomó el primer partido de cada combinación (clase real, predicción del NB), cubriendo las nueve celdas de su matriz. Es una regla reproducible e ilustrativa, no una muestra representativa. El 11/03/2024, Montevideo Wanderers–Deportivo Maldonado terminó 0–0 y NB predijo E. El 17/02/2024, CA Fenix–Danubio terminó 1–2 y NB predijo V. Como error, el 07/04/2024, CA Cerro–Rampla Juniors terminó 3–0 y NB predijo E. Los marcadores solo se

recuperaron para describir los casos; no fueron entradas del partido predicho.

Como diagnóstico posterior, se separaron los partidos según el signo de la diferencia de puntos por partido en los últimos cinco antecedentes. NB acierta 116/216 (53,7 %) cuando el local tiene mayor promedio, 15/39 (38,5 %) con igualdad y 95/217 (43,8 %) cuando lo tiene el visitante. El baseline acierta 99, 21 y 98, respectivamente. La mejora de NB se concentra en el primer grupo; en los otros dos obtiene menos aciertos que el baseline. También cambia la composición E/L/V (62/106/48, 9/15/15 y 60/69/88), de modo que este diagnóstico describe escenarios y no demuestra un efecto causal del atributo.

V-C. Alcance y limitaciones

La selección automática no utiliza las filas de test, pero el bloque de 2024–2025 ya había sido inspeccionado en iteraciones anteriores. Estas cifras describen la ejecución final y no constituyen una evaluación confirmatoria sobre un holdout intacto. Además, 2025 llega solo hasta junio y los mismos tres folds se reutilizan para elegir hiperparámetros y atributos. No se realizaron pruebas de significación estadística.

La discretización agrupa valores distintos dentro de un bin; no se comparó el mismo clasificador con idénticos atributos continuos y discretizados para aislar su efecto. Asimismo, una tasa de 0,5 puede ser observada o imputada, y ventanas de distinta extensión pueden producir la misma tasa. Puntos, goles y victorias resumen partidos superpuestos, lo que hace plausible una dependencia entre atributos; no se midió su dependencia condicionada a la clase ni su efecto sobre NB. ID3 puede representar interacciones mediante divisiones sucesivas, aunque su profundidad máxima y la pre poda limitan la complejidad del árbol. Estos aspectos sugieren mejoras a investigar, no causas demostradas de los errores.

VI. CONCLUSIONES

Se construyó un flujo reproducible desde el ZIP original hasta la predicción de partidos, con limpieza, atributos históricos y selección temporal. El NB propio reproduce las decisiones de `CategoricalNB` bajo el mismo dominio de categorías y suavizado equivalente, aportando una comprobación de la implementación. En los 472 partidos evaluados, NB alcanza el mejor accuracy y macro-F1; ID3 y Random Forest superan al baseline de diez años solo en macro-F1.

El empate sigue siendo la principal dificultad. El bosque reconoce más empates, pero ese aumento también genera falsos positivos; NB obtiene un balance global más favorable sin resolver satisfactoriamente esa clase. Como trabajo futuro, se podrían incorporar indicadores explícitos de cantidad de antecedentes y comparar discretizaciones manteniendo fijo el resto del diseño. Cualquier mejora debería seleccionarse con validación temporal y confirmarse sobre partidos nuevos.

USO DE INTELIGENCIA ARTIFICIAL

Se utilizó Codex en el trabajo sobre Naive Bayes y en la revisión e integración del experimento, y Claude en el trabajo sobre ID3. La asistencia de IA incluyó implementación y depuración de código, comprobaciones de reproducibilidad, análisis de resultados y revisión de la redacción. Se contrastaron los resultados mediante ejecución y pruebas; el uso de estas herramientas no sustituye la comprensión de los métodos ni la responsabilidad de los autores sobre la entrega.

REFERENCIAS

- [1] D. Schoch, “football-data,” GitHub repository. [Online]. Available: <https://github.com/schochastics/football-data>