

Predicción de resultados del fútbol uruguayo mediante métodos de aprendizaje supervisado

Thiago Rivas

C.I. 5.475.680-3

Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
thiago.rivas0021@gmail.com

Juan Duarte

C.I. 5.201.302-9

Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
juan.duarte@fing.edu.uy

Agustin Occhiuzzi

C.I. 5.480.562-4

Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
agustin.occhiuzzi@fing.edu.uy

Resumen—En este informe, se estudia la predicción de victoria local, visitante o empate en el fútbol uruguayo mediante atributos históricos causales y validación temporal. Se conserva un conjunto común de 14.705 partidos hasta 2023 y se evalúan 472 de 2024–2025. Para Naive Bayes propio y su versión de scikit-learn, la selección secuencial de suavizado y atributos produce modelos equivalentes de diez entradas, con un accuracy de 0,4619 y macro-F1 0,4281, frente a 0,4619 y 0,3564 del baseline de diez años. Por otro lado el ID3 propio alcanza 0,4661 y 0,4027, y su versión de scikit-learn sobre los mismos códigos, 0,4682 y 0,4109. El bosque aleatorio sobre tasas continuas queda en 0,4386 y 0,4085. La mayor dificultad encontrada son los empates.

Index Terms—aprendizaje supervisado, árboles de decisión, Naive Bayes, predicción deportiva, fútbol uruguayo

I. INTRODUCCIÓN

La predicción de resultados del fútbol uruguayo se plantea como un problema de clasificación supervisada con tres clases, los cuales son victoria local (L), victoria visitante (V) y empate (E). A partir de registros históricos de partidos, se busca construir atributos disponibles antes del encuentro y estimar su resultado. El desafío no es únicamente ajustar un clasificador, también requiere respetar el orden temporal y evitar que el resultado que se intenta predecir intervenga en sus entradas.

Este trabajo aborda la aplicación de herramientas metodológicas a datos reales, la implementación de métodos supervisados y el análisis de sus predicciones. Se implementaron un árbol ID3 con umbral mínimo de ganancia de información, un Naive Bayes categórico con suavizado mediante tamaño equivalente de muestra y el clasificador base de proporción de victorias en los diez años anteriores. El notebook incorpora además árboles de decisión y Random Forest de scikit-learn. La comparación incluye también Naive Bayes categórico de esa biblioteca.

El procesamiento parte de seis tasas históricas de victoria y reserva 2024–2025 para evaluación. Para ambos NB, la validación seleccionó diez atributos, esas tasas más puntos y diferencia de gol por partido de cada equipo en hasta cinco antecedentes previos. Se examinan métricas por clase además de la proporción global de aciertos.

La evaluación final consolidada abarca ambos NB, el ID3 propio, dos árboles de scikit-learn y el random forest, todos

sobre el mismo test. Las curvas de validación se conservan como selección de hiperparámetros y no anticipan conclusiones sobre test.

II. CONJUNTO DE DATOS Y PREPROCESAMIENTO

II-A. Descripción del dataset

Se utiliza el subconjunto de fútbol uruguayo de la colección de David Schoch [1], suministrado en un ZIP con un único CSV. El archivo contiene 15.207 filas y 17 columnas, tras el procesamiento quedan 15.177 partidos, desde el 5 de marzo de 1932 hasta el 30 de junio de 2025. Por tanto, 2025 no representa un año completo. Los campos centrales son fecha, equipos local y visitante, y goles registrados (*gh*, *ga*).

II-B. Limpieza de datos

La carga normaliza espacios y tipos además de exigir goles enteros no negativos. Elimina una repetición exacta. Se identifican siete grupos ambiguos de fecha y par de equipos, incluyendo localías invertidas, por lo que se excluyen sus 16 registros completos, sin elegir un marcador. Además, se descartan cinco filas de prórroga y ocho de penales. Todas estas exclusiones se aplican antes de construir historiales. Se conserva un registro de motivos y líneas del CSV. Las 175 filas admitidas con advertencias de múltiples encuentros de un equipo en una fecha mantienen sus fechas originales, no se dispone de evidencia para corregirlas. La causalidad se entiende respecto de las fechas registradas.

II-C. Construcción de la variable objetivo

Se adopta el resultado reglamentario sobre los registros con *full_time* igual a F. La etiqueta *winner* se define como

$$\text{winner} = \begin{cases} L & \text{si } gh > ga, \\ V & \text{si } gh < ga, \\ E & \text{si } gh = ga. \end{cases}$$

El diccionario de la fuente incluye prórroga y penales en los goles [1], pero no separa marcadores reglamentarios: las ocho filas P del archivo presentan goles iguales. Se excluyen E/P por incertidumbre, sin reconstruir goles ni imponer empates, lo que limita la cobertura del estudio. Los goles actuales y *full_time* no son entradas de los clasificadores.

II-D. Atributos derivados

Se construyen seis tasas: proporción de victorias en los últimos cinco partidos de cada equipo, proporción de victorias de ambos dentro del año calendario, proporción histórica de victorias del local jugando como local y proporción de victorias de ese local frente al visitante con la misma localía. Si hay menos de cinco antecedentes se usan los disponibles, la referencia anual no corresponde necesariamente a una temporada deportiva.

El cálculo recorre fechas y obtiene los atributos de todos los encuentros de un día antes de actualizar cualquier historial de ese día. Así excluye resultados simultáneos y futuros. Cuando no hay antecedentes se asigna 0,5: esto evita equiparar ausencia de historial con cero victorias, pero puede coincidir con una tasa observada y no constituye una categoría independiente. Nombres de equipos y mes no integran las seis entradas; los nombres sirven para enlazar historiales. Para NB se agregan cuatro entradas: puntos por partido y diferencia de gol por partido en hasta cinco antecedentes, para local y visitante. Los puntos son 3/1/0 y la diferencia es goles a favor menos goles en contra; sin antecedentes se asignan 4/3 y 0. Estas diez entradas, seleccionadas por validación, no incluyen goles del partido a predecir.

II-E. Discretización

El discretizador común produce códigos enteros para los modelos propios. Para las tasas de los últimos cinco partidos se fijan cortes en 0,3 y 0,6, es decir, baja si $x < 0,3$, media si $0,3 \leq x < 0,6$ y alta en otro caso. Las otras ocho entradas del NB final usan terciles aprendidos solo con entrenamiento y reutilizados en validación o evaluación. Los cortes repetidos se eliminan, por lo que pueden resultar menos de tres intervalos; los empates entre valores tampoco garantizan grupos de igual tamaño. No existe un intervalo exclusivo para “sin historial”. Los valores numéricos no finitos se imputan con la mediana aprendida en entrenamiento.

II-F. División temporal de datos

Se reservan 14.705 partidos hasta 2023 como set de entrenamiento y 472 de 2024–2025 para evaluación. Los atributos de evaluación incorporan resultados de fechas anteriores del propio período, simulando predicciones sucesivas, sin reajustar el modelo. La misma política rige para el clasificador base: todos disponen de resultados de fechas anteriores, incluidos los del bloque de evaluación.

III. MODELOS

III-A. Clasificador base

TenYearWinRateClassifier compara las tasas causales de victoria de los diez años anteriores, producidas por el mismo constructor de atributos. Incluye resultados de fechas anteriores del bloque evaluado y excluye el día actual. Sin antecedentes asigna 0,5, ante igualdad elige al local. Nunca predice empate y no aprende parámetros ni modifica historiales al predecir.

III-B. Árbol de decisión propio

La implementación utilizada es ID3. En cada nodo selecciona el atributo de mayor ganancia de información y crea una rama por categoría observada. Para un conjunto S , con proporción p_c de ejemplos de clase c , utiliza:

$$H(S) = - \sum_{c \in \{L,V,E\}} p_c \log_2 p_c \quad (1)$$

$$IG(S, A) = H(S) - \sum_{v \in \text{valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad (2)$$

Los términos con $p_c = 0$ se omiten. Cada atributo se usa como máximo una vez por rama. La recursión termina si el nodo es puro, no quedan atributos, se alcanza `max_depth` (8 como default) o ninguna ganancia supera estrictamente `min_info_gain`. Este último criterio realiza preprda. Cada nodo guarda su clase mayoritaria, que sirve de respaldo ante una categoría no observada, los empates se resuelven por orden de clase. El código contempla ramas vacías, aunque la construcción recorre únicamente categorías presentes.

III-C. Naive Bayes propio

MEstimateCategoricalNB estima las probabilidades de clase mediante frecuencias y supone independencia condicional entre atributos. Para el código v del atributo j y la clase c aplica:

$$P(X_j = v | c) = \frac{n_{jvc} + m/K_j}{n_c + m} \quad (3)$$

Aquí n_{jvc} cuenta coincidencias de código y clase, n_c cuenta ejemplos de la clase y K_j es el máximo código de entrenamiento más uno, o el mínimo declarado mediante `min_categories` si es mayor. La grilla declara cuatro códigos en ambos NB, incluso con bins ausentes, en general K_j puede variar entre atributos y un único $\alpha = m/K$ solo es equivalente con un dominio común de tamaño K . El cero queda reservado para desconocidos. El parámetro $m > 0$ es el tamaño equivalente de muestra: reparte un peso total m uniformemente entre las K_j categorías, agregando m/K_j a cada conteo. Se decide por $\arg \max_c [\log P(c) + \sum_j \log P(X_j = x_j | c)]$, con desempate E/L/V. Los códigos fuera del dominio se remiten al cero; el prior de clase $P(c) = n_c/N$ no se suaviza.

III-D. Modelos de referencia de scikit-learn

Se entrenan dos árboles de decisión de scikit-learn con criterio de entropía: uno recibe los mismos códigos discretos que utiliza el ID3 propio, y el otro trabaja directamente sobre las tasas continuas. El Random Forest, por su parte, combina 300 árboles entrenados sobre las tasas continuas, con semilla 42 y ponderación de clases en cada muestra bootstrap (`balanced_subsample`).

Para comparar con el Naive Bayes propio se utiliza CategoricalNB, aplicado sobre la misma discretización y con cuatro códigos por atributo (incluyendo el código reservado para valores desconocidos). Este estimador calcula las probabilidades condicionales como $(n_{jvc} + \alpha)/(n_c + K_j \alpha)$.

Cuando $K_j = 4$ y $\alpha = m/4$, y ambos modelos comparten el mismo prior de clase empírico y las mismas entradas, esta fórmula coincide exactamente con la del NB propio (Ecuación 3). El suavizado indicado se respeta sin trincar, y el prior de clase se aprende a partir de train. En la evaluación final, ambos NB utilizan los mismos diez atributos, mientras que los árboles conservan su configuración original.

IV. EXPERIMENTACIÓN

IV-A. Selección temporal de hiperparámetros

Se validó en los años completos 2021, 2022 y 2023, con entrenamiento expansivo anterior a cada año. Las fechas no se dividen entre conjuntos y cada combinación ajusta un pipeline nuevo por fold. La selección utiliza macro-F1 medio con igual peso por año. El error graficado es $1 - \text{accuracy}$; el error de entrenamiento es de resustitución y no interviene en la elección.

Se exploraron seis umbrales ID3 entre 0 y 0,05, cinco valores de m entre 0,1 y 1000, cinco de $\alpha = m/4$ y doce combinaciones de profundidad (4, 8, sin límite) y hoja mínima (1, 5, 20, 50) del bosque. Este mantiene 300 árboles y semilla 42. Ante empate exacto se favorece menor umbral o suavizado; para el bosque, menor profundidad y mayor hoja.

ID3 seleccionó 0,005 (macro-F1 0,3818), ambos NB seleccionaron el menor suavizado ($m = 0,1$, $\alpha = 0,025$), con macro-F1 0,3635. Sus métricas coinciden, como corresponde al suavizado equivalente con cuatro códigos. Para Random Forest se conservó la configuración del notebook: 300 árboles entrenados sobre las tasas continuas, con semilla 42, ponderación de clases en cada muestra bootstrap y hoja mínima 1, con macro-F1 de validación 0,3753. Se conservaron los dos árboles de referencia y el baseline. El notebook incluye las curvas de validación de ID3 y NB. Estos hallazgos de selección no son una evaluación independiente, el reajuste y el test de todos los modelos se presentan en la sección V.

IV-B. Comparación acotada de atributos

Con hiperparámetros fijos se compararon siete variantes, siendo estos actuales, adición de puntos, diferencia de gol, ambas, tasas históricas de empate y retiro separado de cada historial de localía. Los mismos folds seleccionaron puntos y goles para ID3 y ambos NB, macro-F1 0,4002 y 0,3858, respectivamente, con menor accuracy que sus versiones iniciales. Random Forest conservó las seis tasas crudas y su configuración por defecto (0,3753). Restringir predicciones a L/V, manteniendo todas las verdades E/L/V, redujo macro-F1 en las 28 comparaciones, aunque a veces aumentó accuracy. Son resultados de selección, NB conserva $m = 0,1$ y $\alpha = 0,025$, sin volver a optimizarlos sobre diez atributos ni consultar test. El macro-F1 NB anual es 0,3532, 0,4169 y 0,3742. Reutilizar folds para decisiones sucesivas puede introducir optimismo.

V. RESULTADOS

Ambos NB se ajustaron una vez con los 14.705 partidos hasta 2023 y se evaluaron sobre los mismos 472 encuentros. Los discretizadores y clasificadores permanecen fijos durante




Figura 1. Error y macro-F1 de entrenamiento/validación para ID3; medias de los tres años.




Figura 2. Error y macro-F1 de validación para el NB propio según m ; medias de los tres años, sobre las seis tasas iniciales.

test. Las métricas agrupan todo el bloque; macro-F1 pondera E/L/V por igual y se usa cero para divisiones indefinidas.

Los NB coinciden en las 472 predicciones, conteos y dominios; sus puntajes logarítmicos difieren como máximo $8,9 \cdot 10^{-15}$, sin modificar el argmax. Ambos aciertan 218 partidos, la misma cantidad que el baseline (misma accuracy 0,4619): cada uno corrige 68 errores del otro y pierde otros 68 de sus aciertos, con 150 aciertos en común y 186 fallos compartidos. La diferencia está en el macro-F1 (0,4281 frente a 0,3564), porque el NB reparte sus aciertos entre las tres




Figura 3. Macro-F1 medio de validación del bosque según profundidad y hoja mínima. El bosque final conserva 300 árboles, semilla 42 y ponderación de clases en cada muestra bootstrap.

Tabla I
EVALUACIÓN COMÚN SOBRE LOS 472 PARTIDOS DE 2024–2025

Modelo	Accuracy	Macro-F1
Árbol sklearn (mismos códigos)	0,4682	0,4109
Árbol ID3 propio	0,4661	0,4027
Naive Bayes propio	0,4619	0,4281
Naive Bayes (sklearn)	0,4619	0,4281
Baseline (diez años)	0,4619	0,3564
Random Forest	0,4386	0,4085
Siempre L (referencia)	0,4025	0,1913
Árbol sklearn (tasas crudas)	0,3602	0,3514

clases. Sobre los mismos códigos discretos, el árbol de sklearn llega a 0,4682 de accuracy y 0,4109 de macro-F1, y el ID3 propio queda en 0,4661 y 0,4027. Sobre tasas continuas, el árbol cae a 0,3602 y 0,3514, mientras el bosque con 300 árboles y ponderación de clases alcanza 0,4386 y 0,4085. Como referencia, predecir siempre L daría 0,4025 y 0,1913. No se evaluó significación estadística.

Tabla II
MÉTRICAS POR CLASE SOBRE EL TEST. AMBOS NB TIENEN IDÉNTICOS VALORES

Modelo	Clase	Precision	Recall	F1	n
NB (ambos)	E	0,3068	0,2061	0,2466	131
	L	0,5336	0,6263	0,5763	190
	V	0,4472	0,4768	0,4615	151
Baseline	E	0,0000	0,0000	0,0000	131
	L	0,5021	0,6368	0,5615	190
	V	0,4199	0,6424	0,5079	151
Árbol ID3 propio	E	0,3214	0,1374	0,1925	131
	L	0,4757	0,7737	0,5892	190
	V	0,5140	0,3642	0,4264	151
Árbol sklearn (códigos)	E	0,3281	0,1603	0,2154	131
	L	0,4801	0,7632	0,5894	190
	V	0,5189	0,3642	0,4280	151
Árbol sklearn (crudas)	E	0,2615	0,2595	0,2605	131
	L	0,3990	0,4158	0,4072	190
	V	0,3958	0,3775	0,3864	151
Random Forest	E	0,3298	0,2366	0,2756	131
	L	0,4722	0,6263	0,5385	190
	V	0,4524	0,3775	0,4116	151

V-A. Matrices de confusión

Con filas reales y columnas predichas en orden E/L/V:

$$C_{NB} = \begin{pmatrix} 27 & 60 & 44 \\ 26 & 119 & 45 \\ 35 & 44 & 72 \end{pmatrix}, \quad C_{base} = \begin{pmatrix} 0 & 66 & 65 \\ 0 & 121 & 69 \\ 0 & 54 & 97 \end{pmatrix}.$$

L presenta la mejor precision, recall y F1, seguida de V y de E. De los 254 errores del NB, 104 (40,9 %) corresponden a empates confundidos con victorias: E→L es la confusión más frecuente (60 casos), seguida de E→V (44). Las confusiones L↔V suman 89 (45 y 44), y los falsos empates, 61 (26 y 35). El NB reconoce 27 de los 131 empates reales, mientras que el baseline nunca predice E. Frente al baseline (121 locales y 97 visitantes correctos), el NB baja a 119 y 72 a cambio de esos empates: mejora el F1 de E y L, pero empeora el de V.

Los árboles repiten el mismo patrón con los empates:

$$C_{ID3} = \begin{pmatrix} 18 & 80 & 33 \\ 24 & 147 & 19 \\ 14 & 82 & 55 \end{pmatrix}$$

$$C_{DT} = \begin{pmatrix} 21 & 77 & 33 \\ 27 & 145 & 18 \\ 16 & 80 & 55 \end{pmatrix}$$

$$C_{RF} = \begin{pmatrix} 31 & 67 & 33 \\ 35 & 119 & 36 \\ 28 & 66 & 57 \end{pmatrix}$$

C_{ID3} y C_{DT} aciertan 220 y 221 partidos respectivamente, con la columna L dominante (147 y 145 locales) y solo 18 y 21 empates reconocidos. El bosque reparte mejor los aciertos entre clases (119 locales, 57 visitantes y 31 empates, 207 en total sobre la diagonal), aunque su accuracy global es menor. El árbol entrenado sobre tasas continuas es el peor de los tres: acierta apenas 170 partidos y predice empate 130 veces, con toda la diagonal baja (ver Tabla I).

V-B. Análisis cualitativo

Se ordenaron los partidos por fecha, local y visitante, y se tomó el primero de cada par (resultado real, predicción del NB), cubriendo las nueve celdas posibles de confusión. Es una selección reproducible e ilustrativa, no representativa de las frecuencias reales. El 11/03/2024, Montevideo Wanderers–Deportivo Maldonado terminó 0–0: el NB predijo E y el baseline, L. El 17/02/2024, CA Fenix–Danubio terminó 1–2 y ambos modelos predijeron V. Como ejemplo de error, el 07/04/2024 CA Cerro–Rampla Juniors Futbol Club terminó 3–0: nuevamente el NB predijo E y el baseline, L. Los marcadores se recuperaron del ZIP limpio y en ningún caso se usaron como entradas del modelo.

Se dividió además todo el conjunto de test según el signo de la diferencia de puntos por partido en los últimos cinco antecedentes de cada equipo. Con ventaja local, el NB acierta 113/216 (52,31 %); con igualdad, 15/39 (38,46 %); y con ventaja visitante, 90/217 (41,47 %). El baseline acierta 99, 21 y 98 respectivamente. Este es un diagnóstico posterior a la evaluación, sin búsqueda de umbrales. Una explicación posible es que exista una señal útil de forma local, aunque también cambia la composición de clases en cada grupo (E/L/V: 62/106/48, 9/15/15 y 60/69/88), efecto que no se aisló; el macro-F1 del NB por grupo es 0,3577, 0,3617 y 0,3522.

Varias limitaciones ayudan a contextualizar estos resultados. La discretización pierde diferencias dentro de un mismo bin; los históricos resumen ventanas de distinta extensión y omiten sus denominadores; y una tasa de 0,5 puede ser tanto observada como neutra, por lo que no constituye evidencia de ausencia de historial. Además, tasas, puntos y goles resumen partidos superpuestos, lo que vuelve plausible cierta información compartida entre atributos, aunque no se midió su dependencia condicionada a la clase ni su efecto sobre el desempeño. Estas limitaciones no deben interpretarse como causas demostradas

de los errores observados, sino como líneas abiertas para trabajo futuro.

VI. CONCLUSIONES

El trabajo sobre Naive Bayes completó un flujo íntegro a partir del ZIP original: limpieza de datos, construcción de atributos causales, selección temporal de hiperparámetros, ajuste final y análisis de resultados. Bajo condiciones explícitas de dominio y suavizado, el m-estimate propio reproduce exactamente a `CategoricalNB`, lo que valida la implementación. Frente al baseline, la mejora es modesta en accuracy y considerablemente mayor en macro-F1, aunque no es uniforme entre clases: el empate sigue siendo, en todos los modelos evaluados, la principal fuente de error.

Cabe destacar que la evaluación es secuencial y sobre un 2025 incompleto: las observaciones no equivalen a una predicción simultánea de dos años completos ni constituyen evidencia causal, y ningún resultado de test modificó atributos, suavizado o decisiones tomadas durante la selección de hiperparámetros. Incorporando la evaluación de los árboles, la comparación global para este conjunto de test queda así: el árbol de scikit-learn entrenado sobre los mismos códigos supera a ambos NB en accuracy (0,4682 frente a 0,4619) pero no en macro-F1 (0,4109 frente a 0,4281); el ID3 propio se ubica junto a ambos, y el Random Forest queda por detrás. La discretización de las tasas resulta claramente beneficiosa: el mismo árbol entrenado sobre valores continuos cae a 0,3602 de accuracy. En conjunto, los resultados muestran que, si bien las mejoras sobre el baseline trivial son modestas y el árbol entrenado sobre tasas continuas queda incluso por debajo de él (0,3602 frente a 0,4025), ninguno de los modelos logra resolver satisfactoriamente la clase empate, que permanece como la principal limitación del enfoque basado en tasas históricas de victoria.

Estas cifras reflejan, más que una limitación puntual de NB o ID3, una dificultad estructural del problema. Un resultado de fútbol depende de factores que ninguna tasa histórica captura –lesiones, decisiones arbitrales, clima, estado anímico del plantel– y ambos modelos suponen, de manera explícita, que los atributos son condicionalmente independientes dada la clase (NB) o que alcanza con evaluarlos uno a la vez sobre una partición discreta (ID3). Ninguno de los dos captura interacciones entre atributos: por ejemplo, que una racha positiva del local importe menos si el rival tiene mejor historial head-to-head. La discretización en pocos bins agrava esto, ya que dos partidos con tasas apenas distintas (0,45 y 0,55) pueden terminar en la misma categoría o en categorías opuestas según dónde caiga el corte. A esto se suma que el empate, por definición, es un resultado de “equilibrio” entre dos equipos, y las tasas de victoria usadas como atributos no fueron diseñadas para capturar paridad sino para capturar dominancia; es esperable, entonces, que sea la clase peor predicha en cualquier modelo que dependa únicamente de ese tipo de señal.

USO DE INTELIGENCIA ARTIFICIAL

En la parte de NB se utilizó Codex, mientras que para ID3 se utilizó Claude, con el fin de asistir en el análisis de resultados, consulta de información y asistencia en la redacción.

REFERENCIAS

- [1] D. Schoch, “football-data,” GitHub repository. [Online]. Available: <https://github.com/schochastics/football-data>