

Predicción de resultados del fútbol uruguayo mediante métodos de aprendizaje supervisado

Thiago Rivas
C.I. 5.475.680-3
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
email@fing.edu.uy

2nd Nombre Apellido
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
email@fing.edu.uy

3rd Nombre Apellido
Facultad de Ingeniería
Universidad de la República
Montevideo, Uruguay
email@fing.edu.uy

Resumen—Se estudia la predicción de victoria local, visitante o empate mediante atributos históricos causales y validación temporal. Se usan 14.705 partidos hasta 2023 para entrenamiento y 472 de 2024–2025 para evaluación. La validación anual 2021–2023 selecciona diez entradas para ID3 y ambos Naive Bayes, y seis para Random Forest. En la evaluación final, Naive Bayes obtiene accuracy 0,4788 y macro-F1 0,4454; ID3, 0,4492 y 0,4238; Random Forest, 0,4258 y 0,4219; y el baseline de diez años, 0,4619 y 0,3564. Los dos NB producen las mismas 472 clases predichas. El bloque de evaluación ya había sido inspeccionado, por lo que estos resultados no se presentan como un nuevo holdout intacto.

Index Terms—aprendizaje supervisado, árboles de decisión, Naive Bayes, predicción deportiva, fútbol uruguayo

I. INTRODUCCIÓN

La predicción de resultados del fútbol uruguayo se plantea como un problema de clasificación supervisada con tres clases, los cuales son victoria local (L), victoria visitante (V) y empate (E). A partir de registros históricos de partidos, se busca construir atributos disponibles antes del encuentro y estimar su resultado. El desafío no es únicamente ajustar un clasificador, también requiere respetar el orden temporal y evitar que el resultado que se intenta predecir intervenga en sus entradas.

Este trabajo aborda la aplicación de herramientas metodológicas a datos reales, la implementación de métodos supervisados y el análisis de sus predicciones. Se implementaron un árbol ID3 con umbral mínimo de ganancia de información, un Naive Bayes categórico con suavizado mediante tamaño equivalente de muestra y el clasificador base de proporción de victorias en los diez años anteriores. La comparación incluye CategoricalNB y Random Forest de scikit-learn.

El procesamiento parte de seis tasas históricas de victoria y separa 2024–2025 para evaluación. Para ID3 y ambos NB, la validación seleccionó diez atributos: esas tasas más puntos y diferencia de gol por partido de cada equipo en hasta cinco antecedentes previos. El bosque conserva las seis tasas. Se examinan métricas por clase además de la proporción global de aciertos.

La configuración se elige mediante validación y luego se ajusta una vez con todo el entrenamiento. La evaluación final verificada usa esa configuración congelada; las curvas de validación no son resultados de test.

II. CONJUNTO DE DATOS Y PREPROCESAMIENTO

II-A. Descripción del dataset

Se utiliza el subconjunto de fútbol uruguayo de la colección de David Schoch [1], suministrado en un ZIP con un único CSV. El archivo contiene 15.207 filas y 17 columnas, tras el procesamiento quedan 15.177 partidos, desde el 5 de marzo de 1932 hasta el 30 de junio de 2025. Por tanto, 2025 no representa un año completo. Los campos centrales son fecha, equipos local y visitante, y goles registrados (gh, ga).

II-B. Limpieza de datos

La carga normaliza espacios y tipos además de exigir goles enteros no negativos. Elimina una repetición exacta. Se identifican siete grupos ambiguos de fecha y par de equipos, incluyendo localías invertidas, por lo que se excluyen sus 16 registros completos, sin elegir un marcador. Además, se descartan cinco filas de prórroga y ocho de penales. Todas estas exclusiones se aplican antes de construir historiales. Se conserva un registro de motivos y líneas del CSV. Las 175 filas admitidas con advertencias de múltiples encuentros de un equipo en una fecha mantienen sus fechas originales, no se dispone de evidencia para corregirlas. La causalidad se entiende respecto de las fechas registradas.

II-C. Construcción de la variable objetivo

Se adopta el resultado reglamentario sobre los registros con full_time igual a F. La etiqueta winner se define como

$$\text{winner} = \begin{cases} L & \text{si } gh > ga, \\ V & \text{si } gh < ga, \\ E & \text{si } gh = ga. \end{cases}$$

El diccionario de la fuente incluye prórroga y penales en los goles [1], pero no separa marcadores reglamentarios: las ocho filas P del archivo presentan goles iguales. Se excluyen E/P por incertidumbre, sin reconstruir goles ni imponer empates, lo que limita la cobertura del estudio. Los goles actuales y full_time no son entradas de los clasificadores.

II-D. Atributos derivados

Se construyen seis tasas: proporción de victorias en los últimos cinco partidos de cada equipo, proporción de victorias de ambos dentro del año calendario, proporción histórica de victorias del local jugando como local y proporción de victorias de ese local frente al visitante con la misma localía. Si hay menos de cinco antecedentes se usan los disponibles, la referencia anual no corresponde necesariamente a una temporada deportiva.

El cálculo recorre fechas y obtiene los atributos de todos los encuentros de un día antes de actualizar cualquier historial de ese día. Así excluye resultados simultáneos y futuros. Cuando no hay antecedentes se asigna 0,5: esto evita equiparar ausencia de historial con cero victorias, pero puede coincidir con una tasa observada y no constituye una categoría independiente. Nombres de equipos y mes no integran las seis entradas; los nombres sirven para enlazar historiales. Para la variante de diez atributos de ID3 y NB se agregan cuatro entradas: puntos por partido y diferencia de gol por partido en hasta cinco antecedentes, para local y visitante. Los puntos son 3/1/0 y la diferencia es goles a favor menos goles en contra; sin antecedentes se asignan 4/3 y 0. Estas diez entradas, seleccionadas por validación, no incluyen goles del partido a predecir.

II-E. Discretización

El discretizador común produce códigos enteros para ID3 y ambos NB. Para las tasas de los últimos cinco partidos se fijan cortes en 0,3 y 0,6, es decir, baja si $x < 0,3$, media si $0,3 \leq x < 0,6$ y alta en otro caso. Las otras ocho entradas usan terciles aprendidos solo con entrenamiento y reutilizados en validación o evaluación. Los cortes repetidos se eliminan, por lo que pueden resultar menos de tres intervalos; los empates entre valores tampoco garantizan grupos de igual tamaño. No existe un intervalo exclusivo para “sin historial”. Los valores numéricos no finitos se imputan con la mediana aprendida en entrenamiento.

II-F. División temporal de datos

Se separan temporalmente 14.705 partidos hasta 2023 como set de entrenamiento y 472 de 2024–2025 para evaluación. Los atributos de evaluación incorporan resultados de fechas anteriores del propio período, simulando predicciones sucesivas, sin reajustar el modelo. La misma política rige para el clasificador base: todos disponen de resultados de fechas anteriores, incluidos los del bloque de evaluación.

III. MODELOS

III-A. Clasificador base

TenYearWinRateClassifier compara las tasas causales de victoria de los diez años anteriores, producidas por el mismo constructor de atributos. Incluye resultados de fechas anteriores del bloque evaluado y excluye el día actual. Sin antecedentes asigna 0,5, ante igualdad elige al local. Nunca predice empate y no aprende parámetros ni modifica historiales al predecir.

III-B. Árbol de decisión propio

La implementación utilizada es ID3. En cada nodo selecciona el atributo de mayor ganancia de información y crea una rama por categoría observada. Para un conjunto S , con proporción p_c de ejemplos de clase c , utiliza:

$$H(S) = - \sum_{c \in \{L,V,E\}} p_c \log_2 p_c \quad (1)$$

$$IG(S, A) = H(S) - \sum_{v \in \text{valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad (2)$$

Los términos con $p_c = 0$ se omiten. Cada atributo se usa como máximo una vez por rama. La recursión termina si el nodo es puro, no quedan atributos, se alcanza `max_depth` (8 como default) o ninguna ganancia supera estrictamente `min_info_gain`. Este último criterio realiza preprda. Cada nodo guarda su clase mayoritaria, que sirve de respaldo ante una categoría no observada, los empates se resuelven por orden de clase. El código contempla ramas vacías, aunque la construcción recorre únicamente categorías presentes.

III-C. Naive Bayes propio

MEstimateCategoricalNB estima las probabilidades de clase mediante frecuencias y supone independencia condicional entre atributos. Para el código v del atributo j y la clase c aplica:

$$P(X_j = v | c) = \frac{n_{jvc} + m/K_j}{n_c + m} \quad (3)$$

Aquí n_{jvc} cuenta coincidencias de código y clase, n_c cuenta ejemplos de la clase y K_j es el máximo código de entrenamiento más uno, o el mínimo declarado mediante `min_categories` si es mayor. La grilla declara cuatro códigos en ambos NB, incluso con bins ausentes, en general K_j puede variar entre atributos y un único $\alpha = m/K$ solo es equivalente con un dominio común de tamaño K . El cero queda reservado para desconocidos. El parámetro $m > 0$ es el tamaño equivalente de muestra: reparte un peso total m uniformemente entre las K_j categorías, agregando m/K_j a cada conteo. Se decide por $\arg \max_c [\log P(c) + \sum_j \log P(X_j = x_j | c)]$, con desempate E/L/V. Los códigos fuera del dominio se remiten al cero; el prior de clase $P(c) = n_c/N$ no se suaviza.

III-D. Modelos de referencia

El Random Forest combina 300 árboles entrenados sobre las seis tasas continuas, con semilla 42 y ponderación de clases en cada muestra bootstrap (`balanced_subsample`). El baseline compara las tasas causales de diez años ya descritas.

Para comparar con el Naive Bayes propio se utiliza CategoricalNB, aplicado sobre la misma discretización y con cuatro códigos por atributo (incluyendo el código reservado para valores desconocidos). Este estimador calcula las probabilidades condicionales como $(n_{jvc} + \alpha)/(n_c + K_j \alpha)$. Cuando $K_j = 4$ y $\alpha = m/4$, y ambos modelos comparten el mismo prior de clase empírico y las mismas entradas, esta fórmula coincide exactamente con la del NB propio

(Ecuación 3). El suavizado indicado se respeta sin truncar, y el prior de clase se aprende a partir de train. El ajuste final de ID3 y ambos NB utiliza las diez entradas elegidas por validación. El bosque conserva seis tasas y usa la profundidad y hoja mínima seleccionadas en su grilla.

IV. EXPERIMENTACIÓN

IV-A. Selección temporal de hiperparámetros

Se validó en los años completos 2021, 2022 y 2023, con entrenamiento expansivo anterior a cada año. Las fechas no se dividen entre conjuntos y cada combinación ajusta un pipeline nuevo por fold. La selección utiliza macro-F1 medio con igual peso por año. El error graficado es $1 - \text{accuracy}$; el error de entrenamiento es de resustitución y no interviene en la elección.

Se exploraron seis umbrales ID3 entre 0 y 0,05, cinco valores de m entre 0,1 y 1000, cinco de $\alpha = m/4$ y doce combinaciones de profundidad (4, 8, sin límite) y hoja mínima (1, 5, 20, 50) del bosque. Este mantiene 300 árboles y semilla 42. Ante empate exacto se favorece menor umbral o suavizado; para el bosque, menor profundidad y mayor hoja.

ID3 seleccionó 0,005 (macro-F1 0,3818 sobre seis tasas), ambos NB seleccionaron el menor suavizado ($m = 0,1$, $\alpha = 0,025$), con macro-F1 0,3635. Sus métricas coinciden bajo el dominio común de cuatro códigos. Random Forest seleccionó profundidad sin límite y hoja mínima 20: macro-F1 0,4228 y error 0,5653. Esta configuración controla su ajuste final; se mantienen 300 árboles, semilla 42 y ponderación `balanced_subsample`. El notebook presenta error de entrenamiento y validación para ID3, ambos NB identificados explícitamente (curvas superpuestas) y las doce configuraciones del bosque.

IV-B. Comparación acotada de atributos

Con hiperparámetros fijos se compararon únicamente las seis tasas y esas tasas más puntos y diferencia de gol recientes de ambos equipos, diez entradas. La misma función de validación ajusta cortes fijos $[0,3, 0,6]$ solo para las dos tasas de los últimos cinco partidos; el resto usa terciles aprendidos en cada train. Los mismos folds seleccionaron diez entradas para ID3 y ambos NB: macro-F1 0,4002 y 0,3858, con errores 0,5846 y 0,5723, respectivamente. En empate exacto se prefieren seis entradas. Estas selecciones determinan las columnas del ajuste final; el bosque mantiene las seis tasas. No se reoptimizan hiperparámetros y el cálculo de selección no usa las filas de test. Reutilizar folds para decisiones sucesivas puede introducir optimismo.

V. RESULTADOS

Cada modelo se ajustó una vez con los 14.705 partidos hasta 2023 y se evaluó sobre los mismos 472 encuentros. Discretizadores y clasificadores permanecen fijos. Los atributos de cada partido sí incorporan resultados de fechas anteriores de 2024–2025, como en una secuencia de predicciones; nunca incorporan partidos de la misma fecha. La configuración se congeló a partir de validación, pero este bloque de test ya




Figura 1. Error de entrenamiento/validación y macro-F1 de validación para ID3; medias de los tres años.




Figura 2. Error y macro-F1 para NB propio y sklearn CategoricalNB ($\alpha = m/4$); curvas equivalentes superpuestas sobre las seis tasas iniciales.

había sido inspeccionado en iteraciones anteriores. Por ello no se lo presenta como un nuevo holdout intacto ni como una evaluación confirmatoria independiente.

Tabla I
EVALUACIÓN COMÚN SOBRE LOS 472 PARTIDOS DE 2024–2025

Modelo	Accuracy	Macro-F1
ID3 propio	0,4492	0,4238
Naive Bayes propio	0,4788	0,4454
CategoricalNB (sklearn)	0,4788	0,4454
Baseline (diez años)	0,4619	0,3564
Random Forest	0,4258	0,4219

Los dos NB aciertan 226 encuentros y generan las mismas 472 etiquetas. Esto no significa que sus probabilidades sean bit a bit idénticas: la diferencia absoluta máxima entre vectores es $2,0 \cdot 10^{-15}$, dentro de la precisión numérica y sin alterar el *argmax*. Frente al baseline, NB mejora tanto accuracy (0,4788 frente a 0,4619) como macro-F1 (0,4454 frente a 0,3564). ID3 y Random Forest tienen menor accuracy que el baseline, aunque mayor macro-F1. No se realizaron pruebas de significación.




Figura 3. Error de entrenamiento/validación y macro-F1 de validación del bosque según profundidad y hoja mínima. Se selecciona profundidad sin límite y hoja mínima 20.

Tabla II
MÉTRICAS POR CLASE. AMBOS NB TIENEN IDÉNTICOS VALORES

Modelo	Clase	Precision	Recall	F1	n
NB (ambos)	E	0,3537	0,2214	0,2723	131
	L	0,5475	0,6368	0,5888	190
	V	0,4497	0,5033	0,4750	151
Baseline	E	0,0000	0,0000	0,0000	131
	L	0,5021	0,6368	0,5615	190
	V	0,4199	0,6424	0,5079	151
ID3	E	0,3036	0,2595	0,2798	131
	L	0,4917	0,6211	0,5488	190
	V	0,5000	0,3974	0,4428	151
Random Forest	E	0,2975	0,3588	0,3253	131
	L	0,5725	0,4158	0,4817	190
	V	0,4261	0,4967	0,4587	151

V-A. Matrices de confusión

Con filas reales y columnas predichas en orden E/L/V, las matrices verificadas son:

$$C_{ID3} = \begin{pmatrix} 34 & 64 & 33 \\ 45 & 118 & 27 \\ 33 & 58 & 60 \end{pmatrix}, \quad C_{NB} = \begin{pmatrix} 29 & 54 & 48 \\ 24 & 121 & 45 \\ 29 & 46 & 76 \end{pmatrix},$$

$$C_{RF} = \begin{pmatrix} 47 & 34 & 50 \\ 60 & 79 & 51 \\ 51 & 25 & 75 \end{pmatrix}, \quad C_{base} = \begin{pmatrix} 0 & 66 & 65 \\ 0 & 121 & 69 \\ 0 & 54 & 97 \end{pmatrix}.$$

CategoricalNB comparte la matriz de NB propio. En los cuatro modelos, E tiene el menor F1. NB reconoce 29 de los 131 empates y mejora respecto del baseline en F1 de E y L, pero no de V (0,4750 frente a 0,5079). El bosque reconoce más empates, 47, sin que ello se traduzca en mayor accuracy global.

V-B. Análisis cualitativo

Se ordenaron las predicciones finales por fecha, local y visitante y se tomó el primer partido de cada combinación (clase real, predicción del NB), cubriendo las nueve celdas de su matriz. Es una regla reproducible e ilustrativa, no una muestra representativa. El 11/03/2024, Montevideo Wanderers–Deportivo Maldonado terminó 0–0 y NB predijo E. El 17/02/2024, CA Fenix–Danubio terminó 1–2 y NB predijo V. Como error, el 07/04/2024, CA Cerro–Rampla Juniors terminó 3–0 y NB predijo E. Los marcadores solo se recuperaron para describir los casos; no fueron entradas del partido predicho.

Como diagnóstico posterior, al separar por el signo de la diferencia de puntos recientes, NB acierta 116/216 con ventaja local, 15/39 con igualdad y 95/217 con ventaja visitante; el baseline acierta 99, 21 y 98. La composición E/L/V también cambia entre grupos (62/106/48, 9/15/15 y 60/69/88), por lo que esta partición descriptiva no demuestra un efecto del atributo.

La discretización agrupa valores distintos dentro de un bin, pero esta corrida no incluye un comparador equivalente que permita atribuirle mejoras o errores. Asimismo, una tasa de 0,5 puede ser observada o imputada y los atributos resumen ventanas de distinta extensión. Son límites de representación; el experimento no identifica sus efectos causales sobre las predicciones.

VI. CONCLUSIONES

La corrida verificada completa limpieza, atributos causales, validación temporal, ajuste final y evaluación secuencial. Con el dominio común de cuatro códigos y suavizados equivalentes, NB propio y CategoricalNB producen las mismas decisiones y probabilidades numéricamente equivalentes. NB supera al baseline en accuracy y macro-F1; ID3 y Random Forest solo lo superan en macro-F1. En todos los modelos el menor F1 corresponde a E, observación limitada a estos 472 partidos.

ID3 sí puede representar interacciones mediante divisiones sucesivas condicionadas por nodos anteriores; no impone la independencia condicional de NB. En esta ejecución, su representación está limitada por los atributos discretizados, la profundidad resultante y la prepoda, pero no se aisló el aporte de interacciones. Tampoco se comparó el mismo modelo con y sin discretización, por lo que no se le atribuye causalmente ninguna diferencia de desempeño.

La evaluación incorpora solo información de fechas anteriores y mantiene fijos modelos y cortes, pero 2025 está incompleto y el test ya fue inspeccionado. Las cifras describen esta corrida y no sustituyen una evaluación futura sobre datos nuevos.

USO DE INTELIGENCIA ARTIFICIAL

En la parte de NB se utilizó Codex, mientras que para ID3 se utilizó Claude, con el fin de asistir en el análisis de resultados, consulta de información y asistencia en la redacción.

REFERENCIAS

- [1] D. Schoch, “football-data,” GitHub repository. [Online]. Available: <https://github.com/schochastics/football-data>